

第三章 面向多目标车间静态设施布局的构形空间进化算法

本章主要研究多目标静态设施布局问题(MO-SFLP)。分析 MO-SFLP 需满足的多个目标,建立 MO-SFLP 的数学优化模型。并根据其相应的约束条件,采用弹性区带架构(FBS)的方式将约束进行化解。过去对于车间设施布局问题有很多研究,但大部分都是集中在单目标车间设施布局的基础上,忽略了其他对车间生产效率重要影响的因素,如安全,噪音,邻接关系等,而多目标优化问题(multi-objective optimization problems, MOPs)是在实际中广泛存在而有很难求解的问题。本章采用 CSE 求解 MO-SFLP, CSE 算法具有进化算法良好搜索能力和较强的健硕性,通过引入“构形”和“构形库”的概念,建造了可以用于缩小搜索空间的空间距离,采用 Pareto 非支配排序和基于目标函数距离的非支配解选取策略,从而保证得到优良的结果。算法由 Java 语言实现,实验采用 Intel Core 2, Duo 2.94GHz CPU,内存为 2GB 的 PC 机。

3.1 多目标车间静态设施布局模型

生产车间的静态设施布局问题,即在有限的车间内,为了达到某些目的对生产设施进行有规划的布置。在现实的生产中,由于各生产的设施大多数都是形状大小各异,定义不等面积设施布局问题中构形(在本文中,一个构形就相当于一个合理的车间布局,所有的构形在解空间内都是独立存在的)的特征具有复杂性,因此,在建立 MO-SFLP 模型之前布局需满足如下假设:

- (1) 所给定的车间和各设施均看为矩形,并且忽略其形状细节;
- (2) 设施的面积可以不相同(即设施可能是正方形或者长方形,设施的长和宽在一定范围内可以进行变化);
- (3) 设施可以有不同的摆设方向(即设施可以水平放置,也可进行垂直放置);
- (4) 布局平面为连续型空间布局,物流费移动点计算为矩形中心点,车间内不能存在形状太过于极端的设施;

按照上述假设,得出数学模型如下:

(1) 模型中参数和变量

车间布局的模型如图 3-1 所示。在模型中,车间设施的数量为 n ,设施需满足的优化目标个数为 m ,车间总面积为 A , L 和 H 分别表示车间的长度和宽度, x 轴和 y 轴分别代表车间在长度和宽度的方向,文中模型里其他参数和变量定义如下:

- B 表示布局中设置区带的个数;
- a_i 表示设施 i 的面积;
- f_{ij} 为设施 i 和设施 j 之间的物流量;
- c_{ij} 为设施 i 和设施 j 之间单位物料单位距离的搬运费用;
- r_{ij} 表示设施 i 和设施 j 之间亲密关系等级;
- s_{ij} 表示设施 i 和设施 j 之间距离要求等级;
- γ_{ir}, γ_{il} 分别表示设施 i 的纵横比的上界和下界;
- x_i, y_i 表示设施 i 在坐标图的中心坐标;
- l_i, w_i 表示设施 i 在布局时的长和宽;
- z_i 表示决定设施 i 放置位置且大小介于 $(1, B+1)$ 之间的随机数;
- d_{ij} 表示设施 i 和设施 j 之间用指定度量的中心点的距离;
- l_{ij} 表示设施 i 和设施 j 之间接触周长;
- γ_i 表示单个设施 i 的纵横比;
- p_{ib} 表示设施 i 是否在区带 b 里(1 表示设施 i 是在区带 b 内, 0 表示没有);




图 3-1 车间布局示意图

我们规定在初始的笛卡尔坐标系中, 坐标原点位于车间左下角。很明显, $X=(x_1, y_1, l_1, w_1, x_2, y_2, l_2, w_2, \dots, x_n, y_n, l_n, w_n)$ 就是一个布局 (即一个构形或一个解)。

(2) 目标函数

本文建立的 MO-SFLP 模型考虑到四个不同的目标: 即最小化物料搬运费 (MHC), 最大化亲密关系函数 (CR)、距离要求函数 (DR) 和纵横比满意度函数 (AR)。其形式化描述如下:

$$F_1(X) = \sum_i \sum_j (f_{ij} c_{ij}) d_{ij} \tag{3.1}$$

$$F_2(X) = \sum_i \sum_j r_{ij} l_{ij} \quad (3.2)$$

$$F_3(X) = \sum_i \sum_j s_{ij} d_{ij} \quad (3.3)$$

公式 (3.1) 表示设施之间的总花费的 MHC 应越小越好, 公式 (3.2) 和公式 (3.3) 分别表示布局中总的 CR 和 DR 数值应该尽可能大。亲密关系等级 r_{ij} 是基于设施之间的亲密度, 它描述了车间布局中设施连接关系。距离要求等级 s_{ij} 受设施间环境关系影响而定义。在实际的生产操作中, 环境因素如机械振动、设施噪音、污染或者某些涉及车间工作者的人身安全的因素, 以及有着火灾或爆炸高危险的, 这些设施都需要将它们从其它设施中独立出来, 因此, 在设施间需要存在一个确切的距离衡量值。定义公式 (3.1) 中 d_{ij} 为设施 i 和设施 j 之间中心点的曼哈顿距离, 而公式 (3.3) 中为欧式距离。




图 3-2 纵横比满意度函数

对于 MO-SFLP, 每一个设施都需要有合理的纵横比, 太长或太窄这样形状极端的设施是不能存在于车间之中的。 l_i 和 w_i 表示设施 i 在布局中的长和宽, 于是我们对设施 i 的纵横比定义如下:

$$\gamma_i = \frac{\max\{l_i, w_i\}}{\min\{l_i, w_i\}} \quad (3.4)$$

设施的纵横比在一定的范围内可以进行变化, 但只要纵横比超出了合理的范围, 纵横比满意度函数就会下降。由于制造生产的车间中不能放置形状极端的设施, 故当纵横比的值已经不能被接受时, 评价函数就会立马下降至零。最简单的纵横比满意度函数如图 3-2 所示, 图中横坐标 γ 表示单个设施的纵横比, 纵坐标 ars 代表设施纵横比相对应的满意度的值, 其中 $\gamma_{i,opt}$ 表示设施最优的纵横比的值。

我们规定设施纵横比的上界 γ_{ir} 和下界 γ_{il} 分别为 2.5 和 1, 当车间所有设施纵横比均在 1 和 2.5 之间, 则这是一个合法的布局, 否则便不符合纵横比目标的要求。为了更直观衡量这一约束, 定义如下等式:

$$V = V_r + V_l \quad (3.5)$$

其中:

$$V_r = \sum_{i=1}^n (\gamma_i - \gamma_{ir}), \quad \forall i | \gamma_i > \gamma_{ir} \quad (3.6)$$

$$V_l = \sum_{i=1}^n (\gamma_{il} - \gamma_i), \quad \forall i | \gamma_i < \gamma_{il} \quad (3.7)$$

对于每一个合法的布局, 最大化纵横比满意度函数 AR 如下:

$$F_4(X) = \frac{\sum_{i=1}^n ars_i}{n} \quad (3.8)$$

(3) 约束条件

模型应满足以下约束条件:

$$I_i \cap I_j = \emptyset \quad (3.9)$$

$$x_i - 0.5l_i \geq 0 \quad (3.10)$$

$$x_i + 0.5l_i \leq L \quad (3.11)$$

$$y_i - 0.5w_i \geq 0 \quad (3.12)$$

$$y_i + 0.5w_i \leq H \quad (3.13)$$

$$\sum_{b=1}^B p_{ib} = 1, \quad i = 1, 2, \dots, n \quad (3.14)$$

$$\sum_{i=1}^n p_{ib} \leq n, \quad b = 1, 2, \dots, B \quad (3.15)$$

$$x_i, y_i \geq 0, \quad i = 1, 2, \dots, n \quad (3.16)$$

I_i 代表了设施 i 在车间中所占空间, 式子 (3.9) 表示设施 i 和设施 j 之间不发生嵌入, 约束条件 (3.10) — (3.13) 表示设施在车间中长和宽有明确界限, 设施不能置于车间外, 式子 (3.14) 确保设施必须会在某一区带, 约束 (3.15) 表示区带中设施的数不能超过车间设施总数, 式子 (3.16) 则是设施中心坐标的约束。

3.2 构形空间进化算法

MOEAs 在解决多目标问题上有广泛应用, 但是传统的 MOEAs 有很多缺陷, 比如 Pareto 前端收敛速度比较慢, 且对于解空间的选择效率低, 尤其当目标数为三个或三个

以上时缺陷尤为明显。本节提出了求解 MO-SFLP 的有效算法—构形空间进化算法 (Configuration Space Evolutionary, CSE), 算法能在解空间内进行有效搜索, 并且得到解集具有较好的分布性。

3.2.1 构形空间进化算法思路及算法步骤

构形空间进化算法用于解决 MOPs。和其他算法不同的是, CSE 引入了“构形”和“构形库”的概念, 通过构造一个距离值 d_{space} 智能缩小算法的解空间, 并且结合进化算法中的进化操作 (如选择、交叉和变异等) 和非支配排序选择、Pareto 最优解集等, 增强了寻求最优解的能力, 算法思路如下:

在算法开始的时候, 在构形空间内随机产生 $k_1=50$ 个分散的构形 (相当于一个车间布局)。由于是随机产生的布局, 故设施与设施之间或设施与车间之间存在着大量的嵌入和重叠, 此时采取针对 MO-SFLP 采取 FBS 布局去约束策略 (详见本章 3.2.2 节), 将所有构形进行不嵌入合法化, 此时也叫称为初始构形库 P_{init} 。

基于初始构形库中所有构形的中心坐标, 得出其距离的平均值 d_{avg} 。以构形库中每一个构形为中心, 以 $d_{space}=d_{avg}/2$ 为半径构造与初始构形库相等的圆形区域, 每个构形中心的计算公式如下:

$$o(x, y) = \left(\frac{\sum_{i=1}^n x_i}{n}, \frac{\sum_{i=1}^n y_i}{n} \right) \quad (3.17)$$

其中 n 为布局内矩形设施个数, x_i 和 y_i 是设施 i 的坐标。

从新构形库内随机选择 $k_2=10$ 个构形, 形成种子构形库 P_{seed} 。其中, 初始构形库 P_{init} 经过迭代后更新后形成的构形库称为新构形库 P_{new} 。然后对种子构形进行进化操作 (如选择、交叉、变异等) (详见本章 3.2.3 节), 产生 $k_3=200$ 个新的构形, 再对新产生的构形进行去约束策略 (详见本章 3.2.2 节), 得到 200 个布局合法的构形, 在这称为进化构形库 P_{evolve} 。

运用非支配排序法^[14]和 NFCS 法 (详见本章 3.2.4 节和 3.2.5 节) 从进化构形库 P_{evolve} 内挑选 $k_4=10$ 个优良的构形, 称之为试验构形库 P_{test} 。随后, 利用这 10 个优秀的试验构形对新构形库进行构形更新 (详见本章 3.2.6 节)。一旦新构形库更新的次数达到了 50 次, 我们就缩小圆形区域的面积, 令 $d_{space}=d_{space}/2$ 用于缩小搜索的空间。如果在新构形库内还有未被选择过作为种子构形的构形, 再随机挑选 10 个或者剩下的未被选择的构形作为种子构形。重复上述过程, 直到新构形库内所有构形均被用为种子构形, 此时更

新新构形库 P_{new} 也到了一个极点，从而完成了一轮 CSE 的迭代过程。开始时，初始构形库 P_{init} 是随机产生，经过一轮算法迭代后，产生了新的构形库 P_{new} 。在初始构形库 P_{init} 和新构形库 P_{new} 中选择适应度值高的构形，放入新构形库，作为下一次迭代开始时的初始构形库。重复上述过程，直到满足算法终止条件。




图 3-3 构形空间进化算法流程图

在算法过程中，新构形库内构形数目并不会改变，一直为 50 个构形。在算法结束时，采用非支配排序法和多属性决策的方法^[45]在 Pareto 最优解集中选择若干个最优构形作为最终结果，算法的流程图如图 3-3 所示。

基于上述思路，算法具体步骤描述如下：

Step 1:在构形空间内，随机产生 $k_1=50$ 个初始构形。

Step 2:运用去约束策略,对空间中每一个构形进行不嵌入合法化,形成初始构形库

P_{inti} 。

Step 3:计算 P_{inti} 中所有构形中心坐标的距离平均值 d_{avg} , 以 $d_{space}=d_{avg}/2$ 为半径, 构形为中心点, 构造 50 个的圆形区域。令 $P_{new}=P_{inti}$, $update=0$ 。

Step 4:While (P_{new} 中有未用作种子构形的构形) do

Step 4.1: 从 P_{new} 中随机选择 $k_2=10$ (或剩余个数) 从未被选过的构形,形成种子构形库 P_{seed} 。

Step 4.2: 对 P_{seed} 中的构形进行进化操作 (如选择、交叉、变异等), 由此产生新的 $k_3=200$ 个构形。

Step 4.3: 对新产生构形进行去约束策略合法化, 得到进化构形库 P_{evolve} 。

Step 4.4:运用非支配排序法和最近最远候选解法从 P_{evolve} 中挑出 $k_4=10$ 个优良构形形成试验构形库 P_{test} 。

Step 4.5: 利用 P_{test} 更新 P_{new} , 令 $update=update+1$ 。

Step 4.6: If ($update \geq 50$) then

Step 4.7: 令 $d_{space}=d_{space}/2$, 并且 $update=0$ 。

End if

End while

Step 5:If (满足终止条件) then

Step 5.1: 将 P_{new} 进行非支配排序。

Step 5.2: 将所有非支配等级为 1 的构形挑选出, 作为 Pareto 解集 P_{opt} 。

Step 5.3: 运用多属性决策的方法从 P_{opt} 中挑出最优解 X^* , 转 Step 6。

Else

Step 5.4: 随机产生 50 个初始构形 P_{init} 。

Step 5.4: 采用非支配排序和最近最远候选解法从 $P_{init} \cup P_{new}$ 中, 选出 50 个作为初始构形库 P_{init} , 转 Step 3。

End if

Step 6:输出最终结果 X^* 。

3.2.2 基于 FBS 的基因编码及去约束策略

遗传算法是一种基于自然进化, 高度并行、随机且适用度高的智能算法。在求解问

题的时候，算法以“染色体”的形式将问题的解进行编码，且每一个染色体上布满了基因。通常来说，在算法初始时，需要对种群进行编码，以便于种群的选择、交叉和变异等进化操作，从而产生新个体。




图 3-4 FBS 结构呈现

对于 MO-SFLP，存在着设施与设施间以及设施与车间之间不嵌入的约束，我们采取特别的布局方式—弹性区带架构（FBS）来表示车间设施的布局呈现。FBS 呈现的是一种连续布局方式，布局被分成几条水平或者垂直的区带（列）。设施被放置在平行且宽度不同的区带中，而区带的宽度由它所含的被分割的设施总面积所决定，如图 3-4 所示，同一个区带的设施宽度相同。区带两边都是笔直的通道，所有设施只允许放在一个区带，因此，MO-SFLP 被简化为只要确定区带的个数以及每个区带中所包含的设施即可。

与其他布局形式如切分架构（STS）相比，基于 FBS 的优化布局设计在布局形式上有一定的限制。然而 FBS 也有一些独特的优势，区带形成了一个通道结构的基础，它支持由块状布局转换到实际的设施布局。因此，理论上来说，基于 FBS 块状布局和实际布局的物料费之间的差异是最小的。总之，FBS 是研究人员和实践者继续学习和使用的最重要的布局之一。




图 3-5 由染色体产生的布局呈现

本研究将每一个布局看成是由 n 个基因组成的染色体，每个基因由一个实数 $z_i (i=1,2,\dots,n)$ 编码位置， z_i 是一个介于 1 和 $(B+1)$ 之间的随机数， B 为布局中总的区带数。 z_i 整数部分表示设施位于的区带，小数部分表示在同一区带中设施摆放的次序，数字小的放置在下面。在 MO-SFLP 模型中，所有设施在平面内基于 FBS 结构按照从下往上，从左到右的顺序依次进行放置。图 3-5 呈现了八个设施的 FLP 布局图，在图中第一个设施的基因为 2.53，它表示设施将被放置到区带二，在比较第四个和第七个设施的小数位值（2.11 和 2.89）后，设施一被放置在区带中间。

在算法初始时，为增加解空间多样性，初始构形随机产生。而采用 FBS 结构，设施可根据实数 z_i 在布局平面内进行有次序地放置。此外，由于区带数目和每一区带设施数可变，算法只需搜寻最优解中区带的个数和每一区带内设施的放置方式即可优化目标函数的值。

3.2.3 MO-SFLP 模型的构形进化

在 CSE 中，我们具体介绍选择、交叉和变异进化操作产生新构形，实现对种群的变化和扩充，增强构形空间解的多样性。

（1）选择操作

为了保留上一代种群（ P_{seed} 中所有构形）中优秀的个体，我们采取精英保留策略，即设置一定的精英比例 k_{elite} （本文中设为 $P_{elite}=0.2$ ），然后对上一代种群进行非支配排序以及最近最远候选解的方法选取一定数量的构形保留，直接复制进入下一代种群中。其中，被选择的精英构形数目 N_{elite} 为：

$$N_{elite} = N_{seed} \times k_{elite} \quad (3.18)$$

上式子中， N_{seed} 代表种子构形库 P_{seed} 中的构形数。

（2）交叉操作

交叉操作是两个父代布局（即构形）间产生后代的进程。对种子构形库 P_{seed} 进行交叉操作，扩大解的邻域，希望能产生更优的下一代构形。在本文中，我们实行连续的均匀交叉，通过交叉操作，新产生的构形继承了父代的优良基因。

选择种子构形库 P_{seed} 和新构形库 P_{new} 作为交叉操作的父代构形，当满足交叉概率 k_{cross} 时，将每一个种子构形依次与新构形库中随机选择的构形进行单点交叉（one-point crossover）或多点交叉（multi-point crossover）。

单点交叉如图 3-6(a)所示，即父代选定的交叉为一个。假设布局中包含 7 个设施，当单点交叉位置为 5 时，则父代构形中编号 5 至 7 号设施进行交叉操作。多点交叉如图 3-6(b)所示，即父代选定的交叉为两个。当单点交叉位置为 3 和 5 时，则父代构形中编号 3 至 5 号设施进行交叉操作。




图 3-6 交叉操作

对于 MO-SFLP 模型，我们基于 FBS 采用实数 $z_i(i=1,2,\cdots,n)$ 进行设施位置的确定。在交叉操作中，选择在区间 $(0, 1)$ 均匀分布的一组随机产生值 $\lambda_i(i=1,2,\cdots,n)$ ，且其长度与染色体一致。通过使用以下公式产生后代：

$$z'_{1i} = \lambda_i z_{1i} + (1 - \lambda_i) z_{2i}, \quad \forall i = 1, 2, \cdots, n \tag{3.19}$$

$$z'_{2i} = (1 - \lambda_i) z_{1i} + \lambda_i z_{2i}, \quad \forall i = 1, 2, \cdots, n \tag{3.20}$$

上式中， z_{1i} 和 z_{2i} 分别表示两个父代的基因， z'_{1i} 和 z'_{2i} 分别代表产生子代的基因。对于产生的后代，再进行去约束策略，使构形合法化。在交叉过程中一共产生 200 个构形，从而得到了进化构形库。以 5 个设施为例，具体交叉操作如表 3-1 所示：

表 3-1 进化算法中的交叉操作

父代 1	父代 2	随机数值	子代 1	子代 2
1.25	1.42	0.26	1.38	1.29
2.24	2.45	0.12	2.42	2.27
2.62	3.25	0.12	2.05	2.84
3.55	3.83	0.53	3.68	3.70
4.12	4.45	0.22	4.38	4.19

(3) 变异操作

变异操作有利于增强种群的多样性, 克服当种群交叉后后代的适应值无法达到最优也不再进化后早熟收敛的缺点。首先对选择、交叉后得到的种群进行非支配排序, 找到非支配等级最后的一级进行变异操作。变异操作随机修改了某些布局块, 在种群中引入了新的遗传结构。在 MO-SFLP 模型中, 当被选择的基因满足变异概率 k_{mutate} 时, 则被区间 $(1, (B+1))$ 中任意数代替, 产生如下:

$$z'_i = \begin{cases} z_i + ((B+1) - z_i) \tanh(ku), & \text{if } \tanh(ku) \geq 0 \\ z_i + (z_i - 1) \tanh(ku), & \text{else} \end{cases} \quad (3.21)$$

这里 z_i 为被随机选择变异的基因, z' 为代替原来基因的值。 u 为标准正态分布的随机数, k 为其相关系数。

3.2.4 基于目标函数距离的非支配解选取策略

在 MOPs 中, 优秀的算法需要在非支配解集中维持良好的解的分布, 并将它收敛到 Pareto 最优集。在文中介绍的 NSGA-II^[14]中, 使用了最大拥挤度比较的方法来维持解的分布。随后, 在许多 MOEAs 中, 最大拥挤度的方法被广泛地使用。然而, 它有一个明显的缺陷, 即在高密度空间中的解很难被选中, 从而导致其解空间的分布并不令人满意。因此, 一些学者在基于原始的最大拥挤度方法上进行改进, Kukkonen 和 Deb^[46]提出了一种改进的对非支配的解进行修剪的双目标优化问题的解决方案, 将最小的拥挤距离值逐个去除。在文献[47]中, 针对多 MOPs 提出了一种快速有效的方法, 即基于拥挤度的对非支配解进行裁剪, 并结合了最近邻的解决方案。然而, 在某些情况下这些方法仍然不能得到令人满意的解的分布。

在本文中, 采用最近最远候选解法 (Nearest and Farthest Candidate Solution, NFCS) 代替了传统的最大拥挤度法, 此方法由最佳候选抽样算法启发, 在一定程度上可以解决上述问题。给定一个候选集合 C , 包含了 p 个非支配的个体, 我们需要从集合 C 中选择 $q (\leq p)$ 个优良解从而得到最优解集 A 。在算法开始时将集合 A 设为空集。首先, 对于集合 C 中每一个构形 $X_j (j=1, 2, \dots, p)$, 计算其每一个目标函数值 $F_i(X_j) (i=1, 2, \dots, m)$, 找到每一个目标值最佳 (如静态设施布局模型中 $F_1(X_j)$ 最小, 或 $F_2(X_j)$ 、 $F_3(X_j)$ 、 $F_4(X_j)$ 最大) 时所对应的构形。随后考虑以下两种情况:

(1) 若 $q < m$, 随机选择 q 个目标值最优的构形加入集合 A , 同时从候选集合 C 中删除。

(2) 若 $q \geq m$, 对于每一个目标分别计算其目标函数最佳值, 将对应构形放入集合 A , 同时从候选集合 C 中删除构形。然后从更新后的集合 C 中, 挑选剩余的 u ($u=q-m$) 个构形。对于集合 $C(|C|=u)$ 中每一个解 X_s , 计算构形 X_s 和集合 A 中所有构形的最小距离 (即基于正则目标函数的距离), 然后从集合 C 中找出距离最大值所对应的构形 X_{far} , 加入集合 A , 同时从集合 C 中删除构形。重复上述过程, 直到集合 A 中解的数量等于 q 。

此进程的复杂性取决于非支配排序过程, 故其时间复杂度为 $O(mp^2)$ 。其中 p 为待选取的非支配解的个数, m 为目标函数的个数。当 $p \leq 2n$ 时, 最坏情况下时间复杂度为 $O(mn^2)$ 。在 NFCS 中, 我们定义两个构形 X_s 和 X_t 的距离计算是基于目标函数距离的方法。由于目标函数之间数值差异巨大, 故在计算之前, 我们需要将目标函数正则化 (详见本章 3.2.5 节)。构形 X_s 和 X_t 之间距离计算公式如下:

$$\text{distance}(s, t) = \sqrt{\sum_{i=1}^m (\bar{F}_i(X_s) - \bar{F}_i(X_t))^2} \quad (3.22)$$

其中, $\bar{F}_i(X)$ 是目标函数 $F_i(X)$ 经过正则化之后的值, m 为目标函数的个数。

算法 NFCS 的具体步骤如下:

// 候选集合 C , 包含了 p 个非支配的个体, 被选择的优良个体放入集合 A 。集合 A 大小为 $q(\leq p)$ 。 m 为目标函数的个数。

Step 1: 令 $A = \emptyset$ 。

Step 2: If ($q < m$) then

Step 2.1: 分别计算集合 C 中每一个构形 X_j ($j=1, 2, \dots, p$) 的 m 个目标函数值 $F_i(X_j)$ ($i=1, 2, \dots, m$)。

Step 2.2: 随机选择 q 个目标值最优的构形加入集合 A 。

Else

Step 2.3: 计算集合 C 中每一个构形 X_j ($j=1, 2, \dots, p$) 的目标函数值。

Step 2.4: 将 m 个目标函数最佳值对应构形放入集合 A 。

Step 2.5: 从候选集合 C 中删除上述构形。

Step 2.6: 令 $q = q - m$ 。

Step 2.7: While ($q > 0$) do

Step 2.8: 计算更新后集合 C 中构形 X_s 和集合 A 中所有构形的最小距离 (即基于正则目标函数的距离)

Step 2.9: 从集合 C 中找出距离最大值所对应构形 X_{far} , 加入集合 A 。

Step 2.10:从集合 C 中删除 X_{far} 。

Step 2.11:令 $q=q-1$ 。

End while

End if

Step 3:输出最优解集 A 。

3.2.5 目标函数正则化

基于目标值函数求距离的方法中,可能会因为目标函数值之间差异巨大而导致权重分配不均匀,从而严重影响最优解的搜索。基于此,在计算距离之前,需要对目标函数值进行正则化。我们采用 NSGA-III^[48,49]中的目标函数值正则化的方法。首先计算候选集合 C 中每一个目标函数 $F_i(i=1,2,\dots,m)$ 的最小数值为 G_i^{min} , 然后构造理想点集 $G=(G_1^{min}, G_2^{min}, \dots, G_m^{min})$ 。之后将集合 C 中目标值 $F_i(X)$ 按照下式进行转化:

$$F'_i(X) = F_i(X) - G_i^{min} \quad (3.23)$$

其中, X 为拥有 n 个设施的一个布局, 也就是相当于一个构形(或称为解)。




图 3-7 目标函数为三时使用极值点构造超平面图

其次,找到构形 X 后利用 ASF(achievement scalarizing function)函数定义在每一个 (i -th) 目标轴的极值点(extreme points) $G^{i,max}$, 将其最小化:

$$ASF(X, w) = \max_{i=1}^m \frac{F'_i(X)}{w_i} \quad (3.24)$$

在上述式子中,若第 i 个转化的目标轴 $F_i(i=l)$ ($l=1,2,\dots,m$), 将其相应权重设为 1, 对于剩余的目标轴 $F_i(i \neq l)$, 权重设为 0 (通常使用极小数 10^{-6} 代替)。

最后根据 m 个极值点我们构造出 m 维超平面（如图 3-7 所示，假设目标为三）。超平面和其对应的第 i 个目标坐标轴截距 a_i 是可计算出，若极值点无法构造超平面，则令 $a_i = G^{i, \max}$ 。目标函数则按照下述公式进行正则化：

$$\bar{F}_i(X) = \frac{F'_i(X)}{a_i}, \quad i=1,2,\dots,m \quad (3.25)$$

其中，构造理想点集以及目标值转化时间复杂度均为 $O(mn)$ ，定义极值点时间复杂度为 $O(m^2n)$ ，计算截距 a_i 时需要一个 $m \times m$ 的矩阵求逆，故其时间复杂度为 $O(m^3)$ 。

3.2.6 构形库更新

在 CSE 算法中，构形库的更新是至关重要的一个步骤。对于每一个新试验构形 T ，计算其与新构形库 P_{new} 内每一个构形的欧式距离，找到距离最小的构形 Y ，将构形和构形之间的距离记为 $D(T, Y)$ 。

(1) 若 $D(T, Y) \leq d_{space}$ ，表示构形 T 被包含在构形 Y 构造的圆形区域内，则认为两个构形是相似的。如果构形 T 支配构形 Y ，则将构形 T 加入到新构形库 P_{new} ，同时从 P_{new} 中删除 Y ，以保持构形库中的数目不变。这时，圆形区域由 Y 转移到 T 。若 Y 支配 T ，则保留 Y 而放弃 T 。如果构形 T 和构形 Y 互不支配，则随机选择一个构形去更新构形库 P_{new} 。若构形 T 被挑选了，则圆形区域移向于 T 。




图 3-8 构形空间在算法的搜索进程中变化

(2) 若 $D(T, Y) > d_{space}$ ，表明构形 T 远离现存的圆形区域。此时若构形 T 支配构形库 P_{new} 中任意一个确定的构形 Z ，则从 P_{new} 中移除 Z ，同时将构形 T 加入，圆形区域由 Z 移向 T 。若构形 T 不能支配 P_{new} 中任一构形，则移除 T 。

很显然，当构造的圆形区域较大时，情形一($D(T, Y) \leq d_{space}$)发生几率很大，反之，

当圆形区域较小时,情形二($D(T, Y) > d_{space}$)更容易发生。当 d_{space} 较大时可以产生更为多样性的解,而较小值导致更快地收敛到次优构形,其代价是极大可能陷入局部极值点而无法找到真正的最优解。因此,为了保障在构形空间内搜索的有效性,需要在算法初期阶段维持解的多样性,然后逐渐将重点转移到下一代优化构形上。在构形空间进化算法中,通过缓慢降低 d_{space} 的值实现上述要求(如图 3-8 所示)。

3.3 算法测试及评价

3.3.1 一个多目标静态设施布局的经典算例

MO-SFLP经典算例引用于文献[50],1963年,Aromur和Buffa^[51]提供了经典算例的数据,此后算例分别被Wang等^[52]、Scholz等^[42]以及Liu和Meller^[5]引用。求解的目标和需满足的约束即为文中第三章中式子3.1-式子3.16。表3-2中给出了20个设施的面积,设施间之间物流量和单位物料单位距离的搬运费用引自于文献[51]。亲密关系等级和距离要求等级矩阵如表3-3和表3-4所示。每个设施的纵横比满意度函数如图3-2所示。

表 3-2 经典静态设施布局算例中设施面积

设施	1	2	3	4	5	6	7	8	9	10
面积	27	18	27	18	18	18	9	9	9	24
设施	11	12	13	14	15	16	17	18	19	20
面积	60	42	18	24	27	75	64	41	27	45

表 3-3 设施间亲密关系等级

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
6							4		4		4									
9												8		8						8
11							2							2						2

算法独立运行10次后,选出一组最优且目标函数值之间互不支配的Pareto解集,运用多属性决策ElectreIII^[45]的方法从中挑选出四个最优解。表3-5和表3-6给出了分别给出了四个最优解的四个目标结果以及最优解的染色体编码,图3-9呈现了相应的布局图。算法运行的结果与文献[50]中使用切分架构(STS)的非支配排序多目标遗传算法(MOGA)进行比较。结果显示,本文运行的算法结果能支配文献中所有的解,也表明本文算法的有效性。图3-9中,有亲密关系和距离要求(表3-3和表3-4)的设施分别用深灰色和浅灰

色进行标注。解1*和解2*（表3-5和表3-6）为文献[50]中的最优解集。


表 3-4 设施间距离要求等级

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1				8	8			8					8		8			8		
2				2	2			2					2		2			2		
3				4	4			4					4		4			4		


表 3-5 经典算例中本文 CSE 与 MOGA 最优解集的对比

算法	解	$F_1(X)$ (min)	$F_2(X)$ (max)	$F_3(X)$ (max)	$F_4(X)$ (max)	时间
CSE	1	4914	213	3333	0.76	10739s
	2	4979	198	3264	0.81	
	3	4879	162	2640	0.71	
	4	4698	162	2565	0.72	
MOGA	1*	5128	150	1227	0.71	—
	2*	6211	91.5	2218	0.69	


“—”表示文献[50]中未给出MOGA运行时间




(a)



(b)



(c)



(d)

图 3-9 CSE 运行得出最优布局，图(a)，(b)，(c)和(d)分别表示为表 3-5 和表 3-6 中四个 Pareto 最优解

从表3-5中的结果来看，MO-SFLP布局的四个最优目标值分别为4698，213，3333

和0.81。和文献中的最优结果相比,本文算法运行出的MHC比文献减少了 $(5128-4698) / 5128 \times 100\% = 8.39\%$,而亲密关系,距离要求和纵横比满意度函数分别增加了 $(213-150) / 150 \times 100\% = 42\%$, $(3333-2218) / 2218 \times 100\% = 50.27\%$ 和 $(0.81-0.71) / 0.71 \times 100\% = 14.08\%$ 。关于运行的时间,由于文献中并未给出具体的MOGA算法运行时间,所以我们也无法与之相比较,但是从表3-5可以看出,本文CSE的运行时间在合理范围之内。

表 3-6 经典算例中本文 CSE 与 MOGA 最优解集的染色体编码

算法	解	染色体编码
CSE	1	{6.4,2.7,6.0,3.2,2.1,3.9,3.8,3.4,5.4,5.2,4.9,4.6,1.3,3.0,4.2,6.2,1.8,1.5,2.5,5.7}
	2	{6.4,2.6,6.0,3.4,2.0,3.9,2.9,3.6,5.3,5.1,4.8,4.5,1.2,3.1,4.1,6.2,1.7,1.5,2.3,5.7}
	3	{2.8,1.5,1.7,1.2,5.0,3.3,3.1,2.0,3.6,2.6,6.3,6.0,3.9,3.8,5.6,4.7,4.5,5.3,6.1,2.3}
	4	{2.9,1.5,1.7,1.2,4.5,3.3,3.1,2.0,3.6,2.6,6.3,6.1,3.9,3.8,5.3,5.9,4.9,4.6,5.5,2.3}
MOGA	1*	0-0-0-0-15-8-7-6-4-1-20-11-19-2-16-9-5-14-17-10-12-3-18-13
	2*	0-0-0-0-0-1-11-20-15-8-7-6-19-9-4-2-17-16-12-5-3-14-10-18-13

3.3.2 一组不同设施数目的典型算例

为了进一步测试算法的效率,第二至九组算例分别测试了7、8、9、10、20、30、35、62个不同数目MO-SFLP。其中算例O7、O8和O9来自于文献[53],VC10来自于文献[54],Ab20来自于文献[51],SC30和SC35来自于文献[42],Du62来自于文献[55],算例名称中的数字即表示布局中的设施个数。在本文中,采用CSE算法对各个算例进行运算,然后将结果与NSGA-II相比较。与3.1节中MO-SFLP模型有些差异,这八组算例将模型中目标四设施间纵横比满意度函数AR变成一个约束条件,算例O7、O8、O9、Ab20、SC35和Du62需满足每个设施的纵横比不得超过4,SC30需满足每个设施的纵横比不得超过5,算例VC10设施最小长边需大于或等于5。算例中设施间的物流量,每个设施的面积都可在文献[41]中找到,为了公平起见,设施间亲密关系等级和距离要求等级为 $[0, 6]$ 之间产生的随机数,0表示设施间无亲密关系(或距离要求),6表示设施间具有很强的亲密关系(或距离要求)。

将以上算例独立运行10次,表3-7列出了本文CSE算法和NSGA-II对不同设施数目的算例目标结果最好值、平均值和标准差比较。从表中我们可以得知,从整体上看CSE对算例的结果优于NSGA-II。算例O8、Ab20、SC35和Du62中CSE所得三个目标 $F_1(X)$ 、 $F_2(X)$ 和 $F_3(X)$ 的最好值、平均值和标准差均好于NSGA-II。算例O9和SC30中CSE得出目标最好值和平均值优于NSGA-II,仅 $F_2(X)$ 的标准差稍弱于NSGA-II。算例VC10中,虽NSGA-II运行得到 $F_1(X)$ 标准差和 $F_3(X)$ 平均值胜于CSE,但其他结果CSE

所得均优于 NSGA-II。算例 O7 中，CSE 所得 $F_1(X)$ 均优于 NSGA-II，而 NSGA-II 得到 $F_2(X)$ 和 $F_3(X)$ 部分结果略好。从总体上来看，可以发现 CSE 在处理不同数目设施布局问题时，算法得到的结果整体性能较优，无论是在处理小规模算例还是大规模算例时，均能得到不错的结果。

为了证明算法在多代后的优化性能，在图 3-10 和图 3-11 中，我们给出了算例 O8 和算例 Du62 优化目标中物料搬运费 MHC（最小化），亲密关系函数 CR（最大化）和距离要求函数 DR（最大化）进化到多代后的目标最好值和平均值的优化进程。这些数据表明，本文提出的算法收敛速度快，稳定性好。从图中我们可以看出，随着迭代步数的增加，两个算例的物料搬运费（MHC），亲密关系函数（CR）和距离要求函数（DR）的目标最好值和平均值趋于稳定。此外，图 3-12 中分别给出了 Pareto 解集中物料搬运费最小的设计方案的布局图，即本文算法对算例 O9、算例 SC35 和算例 Du62 的 $F_1(X)$ 最优解。




图 3-10 算例 O8 中三个目标经过算法迭代的变化过程，(a)为物料搬运费，(b) 和(c)分别为亲密关系函数和距离要求函数目标值




图 3-11 算例 Du62 中三个目标经过算法迭代的变化过程，(a)为物料搬运费，(b)和(c)分别为亲密关系函数和距离要求函数目标值

表 3-7 CSE 和 NSGA-II 对不同设施数目的算例结果比较

算例	算法	$F_1(X)(\min)$			$F_2(X)(\max)$			$F_3(X)(\max)$		
		最好值	平均值	标准差	最好值	平均值	标准差	最好值	平均值	标准差
O7	CSE	115.60	120.76	4.81	141.2	115.61	16.92	481.53	426.45	21.12
	NSGA-II	120.74	130.74	6.52	156.7	113.33	23.49	499.23	438.83	35.45
O8	CSE	209.93	234.95	5.37	201.4	161.36	18.44	790.64	661.72	89.30
	NSGA-II	217.84	247.20	6.12	196.8	156.41	29.01	783.53	648.65	91.43
O9	CSE	217.61	233.75	10.02	254.9	198.32	25.81	929.42	863.04	50.66
	NSGA-II	233.43	251.94	11.89	233.3	193.44	18.03	892.31	751.83	57.03
VC10	CSE	23511.71	27699.9	3075.75	784.2	636.95	114.01	3680.83	3039.86	299.55
	NSGA-II	26867.24	30397.4	2628.23	764.7	625.50	126.63	3646.63	3116.85	369.14
Ab20	CSE	6850.11	7332.86	833.906	78.51	68.61	5.541	913.16	847.93	42.85
	NSGA-II	7535.63	7898.92	1044.869	77.21	67.83	7.288	896.32	823.75	48.31
SC30	CSE	6252.56	6702.44	360.42	537.53	497.73	22.74	17850.3	16988.4	641.17
	NSGA-II	6899.26	7508.79	452.74	521.23	492.07	22.02	17566.7	16747.8	681.80
SC35	CSE	7665.37	8802.37	822.352	751.26	697.99	34.650	30780.2	29369.4	912.852
	NSGA-II	10255.72	11551.2	1115.367	737.92	669.37	45.329	30332.4	28609.9	1227.84
Du62	CSE	3448249.8	3565539.7	48038.488	6112.9	5814.43	143.35	389407	360100	11956.12
	NSGA-II	3645217.2	3731013.6	50915.419	6066.7	5682.04	272.96	365289	353700	12458.03




图 3-12 算法运行算例物料搬运费最优布局结果图。(a)算例 O9: $F_1(X)=217.66$, $F_2(X)=169.61$, $F_3(X)=644.90$;(b)算例 SC35: $F_1(X)=7665.37$, $F_2(X)=629.87$, $F_3(X)=29930.01$;(c)算例 Du62: $F_1(X)=3448249.8$, $F_2(X)=5530.40$, $F_3(X)=342079.05$.

3.3.3 一个多目标静态设施布局的实际应用算例

在本节中，我们给出一个 MO-SFLP 的实际应用^[56]。为促进区域经济的腾飞发展，某市计划在新开发区内建立一个物流园区。政府规划园区实际占地面积为 420000 平方

米，根据园区内产业类型和交通状况，将其分为 12 个功能区（如表 3-8 所示），如办公区、散货堆场、城市配送区等。此模型和 MO-SFLP 经典算例有所区别，为了使处理物流量更加便捷，功能区之间的水平和垂直方向设有一定宽度的通道(如图 3-13 所示)。




图 3-13 水平和垂直方向均设有通道的三区带布局图

在此 MO-SFLP 模型中， W 为水平方向上通道的宽度，设为 25 米。垂直方向上同一区带内功能区之间的通道宽度为 D ，设为 15 米。物流园总的区带数 B 为 4。物流量，亲密关系等级和距离要求等级如表 3-9 所示。单位物流量单位距离的搬运费用设为 1。

表 3-8 MO-SFLP 实际算例中功能区面积（ m^2 ）

功能区	1	2	3	4	5	6	7	8	9	10	11	12
面积	10000	60000	65000	20000	50000	20000	35000	20000	35000	15000	15000	10000

由于此算例中功能区功能区之间不再之间直接接触，故 MO-SFLP 模型中亲密关系目标函数的计算方式由式子 3.2 改为下式：

$$F_2(X)=\sum_i\sum_jr_{ij}g_{ij} \tag{3.26}$$

其中， r_{ij} 为亲密关系等级， g_{ij} 为邻近度因子，表示出布局结果中功能区之间的相关联的程度。邻近度因子 g_{ij} 的值由功能区之间曼哈顿距离 d_{ij} 以及它们最大可能距离 d_{max} 决定^[57]（如表 3-10 所示）。在此 MO-SFLP 模型中，理想的布局满足物料搬运费最小，亲密关系和距离要求最大，且功能区的纵横比必须在区间 $[0.3, 5]$ 中。

为了能很好地将算法应用到此 MO-SFLP 中，在 FBS 布局的基础上我们引入罚函数的方法。罚函数法是一种通用的约束处理的办法，它增加了约束冲突的程度用于惩罚候选解。由于设施布局的排列都是从下到上，从左往右的排列方式，所以在 y 方向上并不会会有设施超出布局边界。我们只需要考虑 x 轴方向上最后一列区带的设施是否超出边界

外，因此，我们采用下式中的罚函数来处理模型中的约束：

$$A_k = \begin{cases} 1, & \text{if } \max_{i=1,2,\dots,n} (x_i + 0.5l_i) \leq L \\ T, & \text{else} \end{cases} \tag{3.27}$$

其中， A_k 为目标函数物料搬运费的惩罚因子， T 为一个极大值。假定 F_{1k} 为构形 X_k 的物料搬运费的目标函数值，则经过惩罚项处理后的物料搬运费的目标变为：

$$F'_{1k} = F_{1k} \times A_k \tag{3.28}$$

因为在模型中物料搬运费的优化目标是求较小值，在经过迭代之后，如果某个解（布局）不满足约束（式子 3.11），则此解将会由于物料搬运费这一目标过大而被淘汰。将算例独立运行 10 次，同样使用多属性决策 ElectreIII^[45]的方法从 Pareto 解集中挑选出四个最优解。最优解集三个目标函数值和染色体编码分别由表 3-11 和表 3-12 给出，相应的布局图如图 3-14 所示。

表 3-9 MO-SFLP 实际算例中物流量，亲密关系等级和距离要求等级

功能区	1	2	3	4	5	6	7	8	9	10	11	12
物流量												
2						1200	2200	500	4000			
3						2000	5000	700	10000			
4						1000	2500		3000			
5						1500	4000	300	6000			
6								200	2000			
7								200	6000			
8									500			
亲密关系等级 r_{ij}												
1											4	
9		3	3			3						
11		4	4	4	4							
12						4				2		
距离要求等级 s_{ij}												
1		6	6	2	2			4	4			
10		2	2	2				2	2			

表 3-10 邻近度因子 g_{ij} 对应值表

d_{ij}	$[0, d_{\max}/6]$	$[d_{\max}/6, d_{\max}/3]$	$[d_{\max}/3, d_{\max}/2]$	$[d_{\max}/2, 2d_{\max}/3]$	$[2d_{\max}/3, 5d_{\max}/6]$	$[5d_{\max}/6, 1]$
g_{ij}	1	0.8	0.6	0.4	0.2	0

从表 3-11 中，我们不难发现 CSE 运行的结果能全部支配文献[56]中 NSGA-II 所得出的解。其中 CSE 运行的最优物料搬运费比 NSGA-II 最佳值减少 $(1.625-1.569)/1.625 \times 100\%=3.446\%$ ，亲密关系和距离要求目标函数值分别增加了 $(22.7-14.8)/14.8 \times 100\%$

=53.378%和(25846-25330)/ 25330×100%=2.037%。


表 3-11 MO-SFLP 实际算例中 CSE 与 NSGA-II 最优解集的对比

算法	解	$F_1(X)$ (min)	$F_2(X)$ (max)	$F_3(X)$ (max)	时间 (s)
CSE	1	1.581 E+07	21.4	25740	6781s
	2	1.569 E+07	20.6	25441	
	3	1.613 E+07	21.6	25846	
	4	1.604 E+07	22.7	25535	
NSGA-II	1*	1.625 E+07	7.8	20137	—
	2*	2.117 E+07	14.8	17225	
	3*	1.752 E+07	8.6	25330	


“—” 表示文献[56]中未给出NSGA-II运行时间

表 3-12 MO-SFLP 实际算例中 CSE 与 NSGA-II 最优解集的染色体编码


算法	解	染色体编码
CSE	1	{4.79,1.67,2.97,1.38,3.31,3.62,2.31,1.98,2.60,4.00,4.30,4.60}
	2	{4.77,1.68,2.64,1.38,3.04,3.30,2.08,3.71,2.43,4.03,4.29,4.57}
	3	{4.79,1.95,2.89,1.62,3.42,3.63,2.26,1.35,2.57,4.25,3.95,4.53}
	4	{4.78,1.78,2.02,1.37,3.73,3.37,2.62,3.02,2.39,4.27,3.97,4.55}
NSGA-II	1*	{1,5,3,9,7,12,6,8,4,10,11,2,2,3,4,3}
	2*	{3,9,7,8,2,6,4,11,1,10,12,5,3,2,4,3}
	3*	{4,2,8,7,9,3,12,5,11,10,6,1,3,3,3,3}




(a)



(b)



(c)



(d)

图 3-14 MO-SFLP 实际算例中 CSE 运行得出最优布局，图(a)，(b)，(c)和(d)分别表示为表 3-11 和表 3-12 中四个 Pareto 最优解

3.3.4 面向多目标静态设施布局问题的算法性能测试与分析

评价 MOPs 优化解的质量好坏通常很难仅仅通过任何单个的评价指标来确定，其结果必须使用统计分析工具进行验证。在 MOPs 评价方法中，有几项性能指标可用于测试多目标解集的质量。通常来说，在解决 MOPs 中有两个清晰明了的目标：（i）收敛到真正的 Pareto 前端；（ii）Pareto 优化解集中解的多样性。研究者们采用多种方法来设计一个实数向量趋近于每一个 Pareto 前端，从各种不同的方面反映解的质量。

为了分析最终布局的优化目标的性能，我们采用世代距离（Generational distance, GD）和间隔度量（Spacing, SP）。GD 由 Van 等^[58]提出，它计算了由算法得到的解集 Q 和实际 Pareto 最优解集 P^* 之间的平均距离，这段距离由以下公式计算：

$$GD = \frac{\sqrt{\sum_{i=1}^{|Q|} d_i^2}}{|Q|} \tag{3.29}$$

其中， $d_i = \min_{j=1}^{|P^*|} \sqrt{\sum_{k=1}^m (F_k(X_i) - F_k^*(X_j))^2}$, $i=1,2,\dots,|Q|$, m 为目标函数的个数， $F_k^*(X_j)$ 为在 Pareto 最优解集 P^* 中，解 X_j 所对应的第 k 个目标函数的值。 d_i 为每个解和 Pareto 最优解中最近的解之间的欧式距离。当 $GD=0$ 时，即代表这时所有的解都位于 Pareto 前端。GD 的值表示了文中得出的解集和实际 Pareto 前端之间的相对距离，很显然 GD 值越小表明结果越优。

表 3-13 CSE 对 MO-SFLP 经典算例和实际应用算例运行结果的世代距离(GD)和间隔度量(SP)

测试算例	MO-SFLP经典算例（4.1.1）	MO-SFLP 实际应用算例（4.1.3）
GD value	17.03	112.59
Spacing value	5.017	9.163

表 3-14 CSE 对 MO-SFLP 经典算例和实际应用算例每个目标运行结果的数值统计

测试算例	目标	最好值	最差值	平均值	标准差
经典算例	$F_1(X)$	4698	5258	4868.14	190.220
	$F_2(X)$	213	142	178.06	12.764
	$F_3(X)$	3333	2545	2754	175.872
	$F_4(X)$	0.81	0.65	0.69	0.021
实际应用	$F_1(X)$	1.569 E+07	1.892 E+07	1.660E+07	0.112 E+07
	$F_2(X)$	22.7	18.3	19.667	1.063
	$F_3(X)$	25846	22184	24189.31	394.201




图 3-15 经典算例和实际应用算例运行得到的 Pareto 解集分布，其中(a)为经典算例 Pareto 解集分布，(b)为实际应用算例 Pareto 解集分布

表 3-15 CSE 对不同设施数目算例运行结果的世代距离（GD）和间隔度量（SP）

算例	算法	GD value	Spacing value
O7	CSE	4.06	0.846
	NSGA-II	4.57	0.759
O8	CSE	6.62	1.527
	NSGA-II	7.33	1.812
O9	CSE	10.18	2.533
	NSGA-II	13.79	3.706
VC10	CSE	39.31	1.953
	NSGA-II	32.92	2.866
Ab20	CSE	22.05	6.941
	NSGA-II	24.14	7.325
SC30	CSE	16.40	4.761
	NSGA-II	16.77	4.974
SC35	CSE	23.11	6.851
	NSGA-II	27.03	7.099
Du62	CSE	83.40	5.372
	NSGA-II	96.97	7.360

Schott^[59]提出了 SP，它是一个衡量解集中解分布的一致性的工具。方程 4.5 表示在当前解集中的每一点和其最近邻点之间的距离差：

$$SP = \sqrt{\frac{1}{p-1} \sum_{i=1}^p (\bar{D} - D_i)^2} \quad (3.30)$$

这里 $D_i = \min_j \left(\sum_{k=1}^m |F_k(X_i) - F_k(X_j)| \right)$, $i, j = 1, 2, \dots, p$, p 为算法运行后所得到的非支配解集, m 为目标函数的个数, $\bar{D}$ 为所有 D_i 的平均值。其中 $SP=0$ 时意味着所有的非支配解之间的间隔相等, 当解越接近均匀分布时, 相应的 SP 的值就越小。表 3-13 给出了算法对 MO-SFLP 经典算例 (3.3.1) 和 MO-SFLP 实际应用算例 (3.3.3) 运行结果的 GD 值和 SP 值, 结果表明世代距离和解分布的一致性都是令人满意的。表 3-14 中给出了其在独立运行 10 次之后, 每一个目标的最好最差值、平均值和标准差。对于以上两组算例, 标准差的值均比较小, 表明本算法的目标函数值不是分散极端的, 其 Pareto 最优解集如图 3-15 所示, 其中圆圈表示合法的解, 星形点表示 Pareto 最优解。从图形中可以看出, 由构型空间遗传算法得到的图是良好分布且收敛的。

另外, 表 3-15 给出了多组不同设施数目算例中, CSE 和 NSGA-II 的世代距离 (GD) 和间隔度量 (SP) 的值, 从表中可以看出, 对于 O7, NSGA-II 具有比较好的 SP 值, 而 CSE 的解与 Pareto 前端距离值更优一些。VC10 中, CSE 的解分布性较好, 而 NSGA-II 具有较好的 GD 值。对于 O8, O9, Ab20, SC30, SC35 和 Du62 中, CSE 均体现了良好的收敛性和分布的多样性。图 3-16 给出了算例 O7、O9、Ab20 和 SC35 中 CSE 得到的 Pareto 解集, 从图中也可看出 CSE 的解集是趋向于 Pareto 最优解前端。

此外, 为了测试和验证 CSE 中参数的影响, 本文设计了对比实验。在 CSE 中, 通用的参数包括初始构形数目 k_1 , 选择的种子构形 k_2 , 进化得到构形 k_3 和用于更新的试验构形数目 k_4 。对于 CSE, 种子构形 k_2 和进化构形 k_3 主要用于扩大解的可能性, 以便于更新构形库。在本研究中, 主要验证初始构形数目 k_1 和试验构形数目 k_4 对实验的影响。通常来说, 初始构形规模 k_1 影响算法的搜索能力和运行效率, 若 k_1 设置较大可保证构形库的多样性, 提高算法搜索能力, 但不可避免地增加算法计算量。若 k_1 设置较小, 虽降低计算量, 但降低寻找更优解的能力。试验构形数目 k_4 影响算法种群的选择, 若 k_4 设置较大则算法容易提前收敛, 无法找寻全局最优。若 k_4 设置较小, 则无法有效保证更新机制的有效性, 使得足够的优秀构形进入构形库中。我们选取一些具有代表性的值来计算各参数的范围。首先将 k_1 分别设置为 50、100、150 和 200, 而 k_4 固定为 10。同样地, 将 k_4 设置为 5、10、15 和 20, 而将 k_1 固定为 50。算法对两个代表性的算例 O9 和 Ab20 的每个参数独立运行 10 次, 表 3-16 和表 3-17 分别列出了 CSE 对 k_1 和 k_4 不同参

数运行得出的目标的最好值、平均值、标准差和算法运行时间。




图 3-16 不同设施数目算例，CSE 得到的 Pareto 解集分布，其中图(a)(b)(c)(d)(e)从左到右，从上到下分别为算例 O7,O9,Ab20,SC35 和 Du62 对应图形。

表 3-16 CSE 算法对于不同初始构形数目 k_1 的计算结果

算例	k_1	$F_1(X)$ (min)			$F_2(X)$ (max)			$F_3(X)$ (max)			时间 (s)
		最好值	平均值	标准差	最好值	平均值	标准差	最好值	平均值	标准差	
O9	50	217.32	231.22	12.088	262.72	210.91	27.607	989.61	907.09	48.371	1284
	100	215.61	234.75	10.623	211.47	145.75	28.993	846.35	772.29	37.075	2762
	150	214.43	234.88	11.287	221.49	174.38	18.988	984.31	896.54	47.956	4044
	200	212.74	238.02	14.466	208.34	159.08	22.363	906.83	803.63	53.765	5635
Ab20	50	6853.71	7448.45	834.087	78.32	69.41	5.322	924.94	870.86	43.078	2102
	100	6346.88	7989.95	1199.30	77.68	67.20	7.089	835.61	788.90	39.098	3933
	150	6644.73	7758.47	946.31	80.62	67.10	6.659	904.63	850.30	55.130	8765
	200	6318.45	7978.37	875.84	68.43	63.41	8.053	907.31	823.75	49.524	11146

从表中可以看出，当 k_4 固定而 k_1 变化时，算例 O9 和 Ab20 对于目标 $F_1(X)$ 最小值均出现在 k_1 为 200 时，但其平均值均为 k_1 为 50 时较优。O9 中 $F_2(X)$ 和 $F_3(X)$ 最好值和平均值均出现在 k_1 为 50 时，Ab20 中 $F_2(X)$ 平均值、标准差和 $F_3(X)$ 中最好值和平均值均出现在 k_1 为 50 时。由此可知， k_1 为 50 时 CSE 的性能较优，且随着 k_1 的增长，两算例的运行时间均成倍增长。当 k_1 固定而 k_4 变化时，O9 中目标 $F_1(X)$ 最小值出现在 k_4 为 5 时，当 k_4 为 10 时， $F_1(X)$ 平均值， $F_2(X)$ 以及 $F_3(X)$ 的最好值、平均值均优于其他 k_4 设定

值。Ab20 中当 k_4 为 10 时三个目标均得到了其最优的最好值和平均值。 k_4 对运行时间影响并未很大，当 k_4 为 15 时两个算例的运行时间较短，但得到的结果一般。

表 3-17 CSE 算法对于不同试验构形数目 k_4 的计算结果

算例	k_4	$F_1(X)$ (min)			$F_2(X)$ (max)			$F_3(X)$ (max)			时间 (s)
		最好值	平均值	标准差	最好值	平均值	标准差	最好值	平均值	标准差	
O9	5	211.43	231.53	11.679	236.63	185.47	31.315	921.44	842.26	50.979	1145
	10	217.32	231.22	12.088	262.72	210.91	27.607	989.61	907.09	48.371	1284
	15	217.78	236.78	12.484	205.77	162.95	26.509	805.62	723.26	39.675	1130
	20	215.64	232.86	9.524	193.57	146.56	21.257	909.13	807.30	46.882	1396
Ab20	5	7277.38	8821.80	1013.11	73.96	61.30	5.883	905.33	822.25	50.871	1808
	10	6853.71	7448.45	834.087	78.32	69.41	5.322	924.94	870.86	43.078	2102
	15	6854.43	7614.50	841.998	70.69	63.92	5.171	904.36	830.33	43.539	1783
	20	6974.51	7937.70	861.252	72.88	65.17	4.468	912.71	865.11	38.696	2394

3.4 本章小结

本章以静态车间设施布局问题为背景，在 MOPs 的基础上建立多目标静态设施布局问题（MO-SFLP）模型，并采用 FBS 架构将模型约束进行转换。采用精英策略和进化操作增加种群多样化，同时结合非支配排序法和基于目标函数正则化非支配解选取策略对优良解的挑选和排序。最后利用构造的圆形区域大小变化，使算法既能产生多样的解又能加快收敛到 Pareto 前端的速率。最后通过 10 组典型的静态测试算例对算法进行了测试，并对算法的性能进行分析。